CĐ-02 · Giải tích và tối ưu

Luyện kiến thức: không tính giờ, chọn xong là biết đúng/sai và xem giải thích. Tiến độ lưu riêng với Luyện đề.

Mã đề **PETER-CD02-3122** · Người làm: Peter: gửi mã này cho mentor khi chữa bài.

Phần A — Nhận biết

Câu 1 · T02-A08 · 3,5 điểm · Điền số · Nhận biết · tình huống

Một mô hình dự đoán giá căn hộ (đơn vị: tỷ đồng). Trên 3 căn của tập kiểm thử: giá thật $(3, 5, 2)$, giá dự đoán $(2, 7, 2)$. Tính MSE (trung bình bình phương sai số) của mô hình. **Nhập số, làm tròn 2 chữ số thập phân.**

Nhập số

Kiểm tra

Câu 2 · T02-A04 · 3 điểm · Trắc nghiệm · Nhận biết

Với hàm khả vi $f : \mathbb{R}^n \to \mathbb{R}$ và một điểm $\mathbf{x}$ có $\nabla f(\mathbf{x}) \neq \mathbf{0}$, phát biểu nào **đúng** về vector gradient $\nabla f(\mathbf{x})$?

- **A.** Chỉ hướng làm f tăng nhanh nhất, tốc độ tăng là $\|\nabla f(\mathbf{x})\|$
- **B.** Luôn có độ dài bằng 1 vì là vector chỉ hướng
- **C.** Luôn chỉ thẳng tới điểm cực tiểu toàn cục của f, bất kể hình dạng của hàm
- **D.** Chỉ hướng làm f giảm nhanh nhất tại $\mathbf{x}$

✓ Chính xác!

Tuyệt, sang câu tiếp theo thôi.

Đáp án A. (bản in: D) Đạo hàm theo hướng đơn vị $\mathbf{u}$ là $\nabla f \cdot \mathbf{u} = \|\nabla f\| \cos\theta$, lớn nhất khi $\mathbf{u}$ cùng hướng ∇f và giá trị lớn nhất là $\|\nabla f\|$.

- **B:** Gradient không được chuẩn hoá; độ dài của nó đo độ dốc và bằng 0 tại điểm dừng.
- **C:** Gradient chỉ là thông tin **cục bộ** tại $\mathbf{x}$; với thung lũng hẹp hoặc hàm không lồi, nó có thể lệch xa hướng tới cực tiểu.

- **D:** Hướng giảm nhanh nhất là $-\nabla f$; đó là lý do gradient descent đi **ngược** gradient.

▸ Giải thích chi tiết

Thử lại câu này

Câu 3 · T02-A03 · 3 điểm · Trắc nghiệm · Nhận biết

Một lớp tuyến tính không bias tính $\mathbf{y} = W\mathbf{x}$, với $\mathbf{x} \in \mathbb{R}^4$ và $\mathbf{y} \in \mathbb{R}^2$. Ma trận Jacobian $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ (quy ước: hàng i ứng với y_i, cột j ứng với x_j) là:

- **A.** $\mathbf{x}^\top$, kích thước 1×4
- **B.** W, kích thước 2×4
- **C.** $W^\top W$, kích thước 4×4
- **D.** $W^\top$, kích thước 4×2

✗ Chưa đúng: bạn chọn A, đáp án đúng là B.
Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án B. $y_i = \sum_j W_{ij} x_j$ nên $\frac{\partial y_i}{\partial x_j} = W_{ij}$: Jacobian chính là W, kích thước (số đầu ra) × (số đầu vào) $= 2 \times 4$.

- **A:** Nhầm với đạo hàm theo **trọng số** của một đầu ra: $\frac{\partial y_i}{\partial W_{i,:}} = \mathbf{x}^\top$.
- **C:** Nhầm với ma trận $X^\top X$ hay gặp trong Hessian của bình phương tối thiểu; Jacobian của ánh xạ tuyến tính chỉ là W.
- **D:** Nhầm quy ước bố cục (layout); $W^\top$ xuất hiện khi lan truyền ngược gradient $\frac{\partial L}{\partial \mathbf{x}} = W^\top \frac{\partial L}{\partial \mathbf{y}}$, không phải Jacobian theo quy ước đã cho.

▸ Giải thích chi tiết

Thử lại câu này

Câu 4 · T02-A01 · 3 điểm · Trắc nghiệm · Nhận biết

Hàm $f(x) = \sqrt{1 + x^2}$ (dạng của pseudo-Huber loss) có đạo hàm $f'(x)$ bằng:

- A. $\dfrac{x}{\sqrt{1+x^2}}$
- B. $\dfrac{1}{2\sqrt{1+x^2}}$
- C. $\dfrac{x}{1+x^2}$
- D. $\dfrac{2x}{\sqrt{1+x^2}}$

✓ Chính xác!

Giỏi lắm, giữ nhịp này nhé.

Đáp án A. Quy tắc chuỗi với $u = 1 + x^2$: $f'(x) = \frac{1}{2\sqrt{u}} \cdot u' = \frac{1}{2\sqrt{1+x^2}} \cdot 2x = \frac{x}{\sqrt{1+x^2}}$.

- **B:** Chỉ lấy đạo hàm của hàm ngoài $\sqrt{u}$ mà quên nhân đạo hàm hàm trong $u' = 2x$.
- **C:** Nhầm sang đạo hàm của $\frac{1}{2}\ln(1+x^2)$; căn bậc hai và logarit có đạo hàm khác nhau.
- **D:** Nhân đạo hàm hàm trong $2x$ nhưng quên hệ số $\frac{1}{2}$ của $(\sqrt{u})' = \frac{1}{2\sqrt{u}}$.

▸ Giải thích chi tiết

Thử lại câu này

Câu 5 · T02-A06 · 3 điểm · Trắc nghiệm · Nhận biết · tình huống

Bạn huấn luyện một mô hình phân loại ảnh. Loss theo từng epoch: $2{,}30 \to 4{,}85 \to 37{,}2 \to 1{,}9 \times 10^{4} \to$ `nan`. Dữ liệu đã chuẩn hoá, hàm loss đã được kiểm đúng. Nguyên nhân khả dĩ nhất là gì?

- A. Learning rate quá lớn, mỗi bước vượt quá cực tiểu và bị khuếch đại dần
- B. Learning rate quá nhỏ nên mô hình chưa kịp học được gì sau vài epoch
- C. Mô hình đang overfitting, ghi nhớ tập huấn luyện nên loss tăng dần
- D. Batch size quá lớn nên gradient quá chính xác, làm quá trình học mất ổn định

✓ Chính xác!

Chính xác, bạn nắm chắc phần này.

Đáp án A. Loss **tăng theo cấp số nhân** rồi thành `nan` là dấu hiệu kinh điển của bước quá lớn: với loss bậc hai $L = \frac{\lambda}{2} w^2$, GD cho $w_{t+1} = (1 - \eta\lambda) w_t$, phân kỳ khi $\eta > 2/\lambda$.

- **B:** Learning rate quá nhỏ làm loss giảm **chậm** hoặc gần như đứng yên, không làm loss tăng vọt.
- **C:** Overfitting làm loss trên **validation** tăng trong khi loss huấn luyện vẫn giảm; ở đây chính loss huấn luyện bùng nổ.
- **D:** Batch lớn làm gradient ít nhiễu hơn, thường **ổn định** hơn; nó không gây bùng nổ nếu learning rate hợp lý.

▸ Giải thích chi tiết

Thử lại câu này

Câu 6 · T02-A07 · 3 điểm · Trắc nghiệm · Nhận biết

Hàm sigmoid $\sigma(z) = \dfrac{1}{1 + e^{-z}}$ có đạo hàm $\sigma'(z)$ bằng:

- A. $\sigma(z)^2$
- B. $\dfrac{1}{(1 + e^{-z})^2}$
- C. $\sigma(z)\,\big(1 - \sigma(z)\big)$
- D. $1 - \sigma(z)^2$

✗ Chưa đúng: bạn chọn A, đáp án đúng là C.
Đọc lý do bên dưới rồi bấm "Thử lại câu này".

Đáp án C. $\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} = \sigma(z)\big(1 - \sigma(z)\big)$; lớn nhất bằng $0{,}25$ tại $z = 0$.

- **A:** Chỉ lấy một thừa số $\frac{1}{1+e^{-z}}$ hai lần; thừa số thứ hai đúng ra là $\frac{e^{-z}}{1+e^{-z}} = 1 - \sigma(z)$.
- **B:** Đạo hàm $(1 + e^{-z})^{-1}$ nhưng quên nhân đạo hàm hàm trong $(1 + e^{-z})' = -e^{-z}$ (quy tắc chuỗi).
- **D:** Đây là đạo hàm của $\tanh$: $\tanh'(z) = 1 - \tanh^2(z)$, dễ nhầm vì hai hàm cùng dạng chữ S.

▸ Giải thích chi tiết

Thử lại câu này

Câu 7 · T02-A05 · 3 điểm · Trắc nghiệm · Nhận biết

Quy tắc cập nhật của gradient descent với learning rate $\eta > 0$, tham số $\mathbf{w}$ và hàm mất mát L là:

- A. $\mathbf{w} \leftarrow \mathbf{w} - \nabla L(\mathbf{w})/\eta$
- B. $\mathbf{w} \leftarrow \eta\mathbf{w} - \nabla L(\mathbf{w})$
- C. $\mathbf{w} \leftarrow \mathbf{w} + \eta\nabla L(\mathbf{w})$
- D. $\mathbf{w} \leftarrow \mathbf{w} - \eta\nabla L(\mathbf{w})$

✗ Chưa đúng: bạn chọn A, đáp án đúng là D.
Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án D. (bản in: B) Đi một bước nhỏ ngược hướng gradient: $\mathbf{w}_{t+1} = \mathbf{w}_t - \eta\nabla L(\mathbf{w}_t)$. Với η đủ nhỏ, L giảm vì $L(\mathbf{w} - \eta\mathbf{g}) \approx L(\mathbf{w}) - \eta\|\mathbf{g}\|^2$.

- **A:** Chia cho η khiến learning rate nhỏ lại cho bước **lớn**; η phải nhân với gradient.
- **B:** Nhân η vào chính $\mathbf{w}$ làm co tham số (giống weight decay quá đà) và bỏ mất vai trò bước nhảy của η.
- **C:** Đi **theo** gradient là gradient ascent: làm L tăng (dùng khi cực đại hoá, không phải khi giảm loss).

▸ Giải thích chi tiết

Thử lại câu này

Câu 8 · T02-A02 · 3 điểm · Trắc nghiệm · Nhận biết

Trong một đồ thị tính toán, $z = g(x)$ rồi $y = f(z)$, với f và g khả vi. Theo quy tắc chuỗi, $\dfrac{dy}{dx}$ bằng:

- A. $f'(x) \cdot g'(x)$
- B. $f'\big(g'(x)\big)$
- C. $f'\big(g(x)\big) \cdot g'(x)$

- D. $f\big(g(x)\big) \cdot g'(x)$

✗ Chưa đúng: bạn chọn A, đáp án đúng là C.
Ghi câu này vào sổ lỗi, lần sau sẽ nhớ.

Đáp án C. $\frac{dy}{dx} = \frac{dy}{dz} \cdot \frac{dz}{dx} = f'(z)\,g'(x) = f'\big(g(x)\big)\,g'(x)$: đạo hàm hàm ngoài **tính tại giá trị hàm trong**, nhân đạo hàm hàm trong.

- **A:** Tính f' tại x thay vì tại $z = g(x)$. Ví dụ $f = \sin$, $g(x) = x^2$ cho $\cos(x) \cdot 2x$, sai so với $\cos(x^2) \cdot 2x$.
- **B:** Lồng đạo hàm vào nhau như hợp hàm; quy tắc chuỗi là **tích** của các đạo hàm chứ không phải hợp của chúng.
- **D:** Quên lấy đạo hàm hàm ngoài: giữ nguyên $f(g(x))$ rồi chỉ nhân $g'(x)$.

▸ Giải thích chi tiết

Thử lại câu này

Phần B — Thông hiểu

Câu 9 · T02-B10 · 3 điểm · Trắc nghiệm · Thông hiểu

Một mạng có 10^6 tham số và loss là một số vô hướng L. Vì sao các framework dùng backprop (reverse-mode autodiff: áp quy tắc chuỗi từ L ngược về các tham số) thay cho forward-mode?

- **A.** Một lượt ngược cho đủ 10^6 đạo hàm $\partial L/\partial w_i$; forward-mode cần cỡ một lượt cho mỗi tham số
- **B.** Quy tắc chuỗi chỉ đúng khi nhân các đạo hàm theo thứ tự từ đầu ra về đầu vào
- **C.** Reverse-mode không cần lưu giá trị trung gian của lượt xuôi nên tiết kiệm bộ nhớ
- **D.** Reverse-mode cho kết quả chính xác, còn forward-mode chỉ xấp xỉ bằng sai phân hữu hạn

✓ Chính xác!
Giỏi lắm, giữ nhịp này nhé.

Đáp án A. (bản in: B) Với $f : \mathbb{R}^n \to \mathbb{R}^m$, forward-mode tốn cỡ n lượt, reverse-mode cỡ m lượt. Ở đây $n = 10^6$, $m = 1$ nên reverse-mode rẻ hơn khoảng 10^6 lần.

- **B:** Phép nhân ma trận Jacobian có tính kết hợp nên thứ tự nào cũng cho cùng kết quả; thứ tự chỉ ảnh hưởng **chi phí**.
- **C:** Ngược lại: reverse-mode phải **lưu** các activation của lượt xuôi để dùng khi đi ngược, đó là lý do huấn luyện tốn bộ nhớ.
- **D:** Cả hai chế độ autodiff đều cho đạo hàm **chính xác** (tới sai số dấu phẩy động); sai phân hữu hạn là kỹ thuật khác.

▸ Giải thích chi tiết

Thử lại câu này

Câu 10 · T02-B04 · 3,5 điểm · Điền số · Thông hiểu

Cho $f(x, y) = 3x^2 + xy - 2y^2$. Tính đạo hàm theo hướng của f tại điểm $(1, 2)$ theo hướng của vector $\mathbf{v} = (3, 4)$ (dùng vector **đơn vị** cùng hướng với $\mathbf{v}$). **Nhập dạng thập phân, làm tròn 1 chữ số.**

Nhập số

Kiểm tra

Câu 11 · T02-B05 · 3 điểm · Trắc nghiệm · Thông hiểu

Loss của một mô hình có dạng thung lũng hẹp và dài: rất dốc theo w_1, rất thoải theo w_2. GD thuần dao động zig-zag qua lại theo w_1 và tiến rất chậm theo w_2. Thêm momentum $\mathbf{v}_t = \beta \mathbf{v}_{t-1} + \nabla L(\mathbf{w}_{t-1})$, $\mathbf{w}_t = \mathbf{w}_{t-1} - \eta \mathbf{v}_t$ giúp được vì sao?

- **A.** Momentum tự giảm learning rate mỗi khi loss tăng nên hết dao động
- **B.** Momentum dùng thêm thông tin Hessian nên đi thẳng tới cực tiểu giống phương pháp Newton
- **C.** Gradient theo w_1 đổi dấu nên triệt tiêu trong $\mathbf{v}$, theo w_2 cùng dấu nên cộng dồn
- **D.** Momentum bảo đảm tìm được cực tiểu toàn cục kể cả khi loss không lồi

✗ Chưa đúng: bạn chọn A, đáp án đúng là C.

Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án C. $\mathbf{v}_t = \sum_k \beta^k \nabla L(\mathbf{w}_{t-1-k})$ là tổng có trọng số của các gradient cũ: thành phần đổi dấu bị triệt tiêu, thành phần cùng dấu tích luỹ tới cỡ $\frac{1}{1-\beta}$ lần.

- **A:** Momentum không theo dõi loss và không đổi η; điều chỉnh learning rate là việc của scheduler hoặc line search.
- **B:** Momentum chỉ dùng gradient (đạo hàm cấp một); nó không tính hay xấp xỉ Hessian như phương pháp Newton.
- **D:** Momentum có thể giúp vượt qua vùng phẳng nhỏ nhưng không có đảm bảo cực tiểu toàn cục cho hàm không lồi.

▸ Giải thích chi tiết

Thử lại câu này

Câu 12 · T02-B02 · 3 điểm · Trắc nghiệm · Thông hiểu

Cho $f(x) = x\,e^{-x^2}$. Đạo hàm $f'(x)$ bằng:

- **A.** $-2x^2e^{-x^2}$
- **B.** $e^{-x^2}(1-2x^2)$
- **C.** $e^{-x^2}(1-2x)$
- **D.** $e^{-x^2}(1+2x^2)$

✗ Chưa đúng: bạn chọn A, đáp án đúng là B.

Ghi câu này vào sổ lỗi, lần sau sẽ nhớ.

Đáp án B. (bản in: D) Quy tắc tích và chuỗi:
$f' = 1\cdot e^{-x^2} + x\cdot e^{-x^2}\cdot(-2x) = e^{-x^2}(1-2x^2)$.

- **A:** Chỉ giữ số hạng $x\cdot(e^{-x^2})'$, bỏ số hạng $x'\cdot e^{-x^2}$ của quy tắc tích.
- **C:** Lấy $(e^{-x^2})' = -2e^{-x^2}$, quên rằng đạo hàm hàm trong là $-2x$ chứ không phải -2.
- **D:** Sai dấu: $(-x^2)' = -2x$, nên số hạng thứ hai mang dấu trừ.

▸ Giải thích chi tiết

Thử lại câu này

Câu 13 · T02-B07 · 3 điểm · Trắc nghiệm · Thông hiểu

Trong Adam, $\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1-\beta_1)\mathbf{g}_t$ với $\mathbf{m}_0 = \mathbf{0}$, sau đó dùng $\hat{\mathbf{m}}_t = \mathbf{m}_t / (1-\beta_1^t)$. Mục đích của phép chia cho $1-\beta_1^t$ là gì?

- **A.** Thay cho việc chia cho $\sqrt{\hat{\mathbf{v}}_t}$, nên có thể bỏ $\mathbf{v}_t$
- **B.** Bù độ lệch về 0 của $\mathbf{m}_t$ ở các bước đầu do $\mathbf{m}_0 = \mathbf{0}$
- **C.** Làm learning rate giảm dần theo thời gian để hội tụ
- **D.** Chuẩn hoá để mọi tham số có cùng độ lớn bước cập nhật

✗ Chưa đúng: bạn chọn A, đáp án đúng là B.

Không sao, sai ở đây là học được nhiều nhất.

Đáp án B. (bản in: D) Với gradient không đổi g: $\mathbf{m}_t = (1-\beta_1^t)g$, nhỏ hơn g nhiều khi t nhỏ (ví dụ $\beta_1 = 0{,}9$, $t = 1$: $m_1 = 0{,}1g$). Chia cho $1-\beta_1^t$ trả về đúng g.

- **A:** $\hat{\mathbf{m}}_t$ (hướng, trung bình gradient) và $\hat{\mathbf{v}}_t$ (thang đo, trung bình bình phương) có vai trò khác nhau; bỏ $\mathbf{v}_t$ là thành SGD momentum.
- **C:** Hệ số $\frac{1}{1-\beta_1^t}$ **giảm dần về 1**, nên nó làm bước đầu lớn lên chứ không phải lịch giảm learning rate.
- **D:** Việc cân bằng độ lớn bước giữa các tham số do phép chia cho $\sqrt{\hat{\mathbf{v}}_t}$ đảm nhận, không phải hiệu chỉnh bias của $\mathbf{m}_t$.

▸ Giải thích chi tiết

Thử lại câu này

Câu 14 · T02-B06 · 3 điểm · Trắc nghiệm · Thông hiểu

Cho $L(w_1, w_2) = (w_1 - 3)^2 + 2(w_2 + 1)^2$. Từ điểm $(w_1, w_2) = (0, 0)$, chạy **một bước** gradient descent với $\eta = 0{,}1$. Điểm mới (w_1, w_2) là:

- **A.** $(0{,}6;\ -0{,}4)$
- **B.** $(0{,}6;\ -0{,}2)$
- **C.** $(-0{,}6;\ 0{,}4)$
- **D.** $(0{,}3;\ -0{,}2)$

✓ Chính xác!

Giỏi lắm, giữ nhịp này nhé.

Đáp án A. (bản in: B) $\nabla L = \big(2(w_1-3),\ 4(w_2+1)\big) = (-6, 4)$ tại $(0,0)$;
$\mathbf{w}_1 = (0,0) - 0{,}1\cdot(-6,4) = (0{,}6;\ -0{,}4)$.

- **B:** Quên nhân hệ số 2 phía trước: $\frac{\partial}{\partial w_2}2(w_2+1)^2 = 4(w_2+1)$ chứ không phải $2(w_2+1)$.
- **C:** Cộng gradient thay vì trừ (đi ngược quy tắc GD), nên loss tăng từ 11 lên 16,88.
- **D:** Quên đạo hàm của bình phương (hệ số 2 từ quy tắc chuỗi) ở cả hai thành phần: dùng $(w_1-3,\ 2(w_2+1))$.

▸ Giải thích chi tiết

Thử lại câu này

Câu 15 · T02-B08 · 3 điểm · Trắc nghiệm · Thông hiểu

Mô hình phân loại K lớp: logits $\mathbf{z}$, $\mathbf{p} = \mathbf{softmax}(\mathbf{z})$, nhãn one-hot $\mathbf{y}$, loss cross-entropy $L = -\sum_k y_k \ln p_k$. Gradient $\dfrac{\partial L}{\partial \mathbf{z}}$ là:

- A. $-\mathbf{y} \oslash \mathbf{p}$ (chia từng phần tử)
- B. $\mathbf{p} \odot (\mathbf{1} - \mathbf{p})$
- C. $\mathbf{p} - \mathbf{y}$
- D. $\mathbf{y} - \mathbf{p}$

✗ Chưa đúng: bạn chọn A, đáp án đúng là C.

Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án C. (bản in: A)
$\frac{\partial L}{\partial z_j} = -\sum_k y_k \frac{\partial \ln p_k}{\partial z_j} = -\sum_k y_k(\delta_{kj} - p_j) = p_j\sum_k y_k - y_j = p_j - y_j$.

- **A:** Đây là gradient theo **xác suất** $\mathbf{p}$; còn phải nhân Jacobian của softmax mới ra gradient theo logits $\mathbf{z}$.
- **B:** Chỉ lấy đường chéo Jacobian softmax $p_j(1-p_j)$, bỏ cả các số hạng chéo $-p_k p_j$ lẫn nhãn $\mathbf{y}$.

- **D:** Sai dấu: đây là $-\nabla L$, tức hướng **giảm** loss mà GD sẽ đi, không phải gradient.

▸ Giải thích chi tiết

Thử lại câu này

Câu 16 · T02-B01 · 3,5 điểm · Điền số · Thông hiểu · tình huống

Một lớp ẩn dùng hàm kích hoạt $f(x) = \ln(1 + e^{2x})$ (softplus có hệ số 2). Tính $f'(x)$ tại $x = \frac{\ln 3}{2}$ (tức là $e^{2x} = 3$). **Nhập dạng thập phân, làm tròn 2 chữ số.**

Nhập số

Kiểm tra

Câu 17 · T02-B03 · 3 điểm · Trắc nghiệm · Thông hiểu

Hồi quy tuyến tính với ma trận dữ liệu $X \in \mathbb{R}^{n \times d}$, nhãn $\mathbf{y} \in \mathbb{R}^n$, tham số $\mathbf{w} \in \mathbb{R}^d$ và loss $L(\mathbf{w}) = \|X\mathbf{w} - \mathbf{y}\|_2^2$. Gradient $\nabla_{\mathbf{w}} L$ là:

- A. $2(X\mathbf{w} - \mathbf{y})$
- B. $2X^\top(X\mathbf{w} - \mathbf{y})$
- C. $2X(X\mathbf{w} - \mathbf{y})$
- D. $2X^\top X$

✗ Chưa đúng: bạn chọn A, đáp án đúng là B.

Không sao, sai ở đây là học được nhiều nhất.

Đáp án B. (bản in: A) Đặt $\mathbf{r} = X\mathbf{w} - \mathbf{y}$, $L = \mathbf{r}^\top \mathbf{r}$. Quy tắc chuỗi: $\nabla_{\mathbf{w}} L = \left(\frac{\partial \mathbf{r}}{\partial \mathbf{w}}\right)^\top 2\mathbf{r} = 2X^\top(X\mathbf{w} - \mathbf{y}) \in \mathbb{R}^d$.

- **A:** Đây là gradient theo **phần dư** $\mathbf{r}$ (vector n chiều), quên nhân Jacobian $\frac{\partial \mathbf{r}}{\partial \mathbf{w}} = X$.
- **C:** Sai kích thước: X là $n \times d$ không nhân được với vector n chiều (trừ khi $n = d$); cần chuyển vị $X^\top$.
- **D:** Đây là **Hessian** $\nabla^2 L = 2X^\top X$ (đạo hàm cấp hai), không phải gradient.

▸ Giải thích chi tiết

Thử lại câu này

Câu 18 · T02-B09 · 3,5 điểm · Điền số · Thông hiểu · tình huống

Mô hình phân loại ảnh 3 lớp (chó, mèo, chim). Trong một batch có 2 ảnh: ảnh 1 nhãn **chó**, xác suất dự đoán (chó, mèo, chim) $= (0{,}7;\ 0{,}2;\ 0{,}1)$; ảnh 2 nhãn **chim**, xác suất dự đoán $= (0{,}25;\ 0{,}5;\ 0{,}25)$. Tính cross-entropy **trung bình** trên batch, dùng logarit tự nhiên. **Làm tròn 3 chữ số thập phân.**

Nhập số

Kiểm tra

Phần C — Vận dụng

Câu 19 · T02-C09 · 3 điểm · Trắc nghiệm · Vận dụng · tình huống

Bộ lọc spam dùng hồi quy logistic $p = \sigma(\mathbf{w}^\top \mathbf{x} + b)$ với loss binary cross-entropy $L = -[y \ln p + (1-y)\ln(1-p)]$. Khởi tạo $\mathbf{w} = (0, 0)$, $b = 0$. Một email có $\mathbf{x} = (1, 2)$, nhãn $y = 1$ (spam). Sau **một bước** GD trên mẫu này với $\eta = 0{,}1$, $\mathbf{w}$ mới là:

- A. $(0{,}0125;\ 0{,}025)$
- B. $(-0{,}05;\ -0{,}1)$
- C. $(0{,}1;\ 0{,}2)$
- D. $(0{,}05;\ 0{,}1)$

✗ Chưa đúng: bạn chọn A, đáp án đúng là D.

Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án D. (bản in: C) $p = \sigma(0) = 0{,}5$; $\nabla_{\mathbf{w}} L = (p-y)\mathbf{x} = -0{,}5 \cdot (1, 2) = (-0{,}5;\ -1)$; $\mathbf{w} \leftarrow \mathbf{0} - 0{,}1 \cdot (-0{,}5;\ -1) = (0{,}05;\ 0{,}1)$.

- **A:** Nhân thêm $\sigma'(0) = 0{,}25$ như khi dùng MSE với sigmoid; với BCE, thừa số σ' đã triệt tiêu nên gradient chỉ là $(p-y)\mathbf{x}$.
- **B:** Cộng gradient thay vì trừ (hoặc dùng $y - p$ làm gradient): trọng số đi ngược hướng, đẩy email spam về phía không spam.
- **C:** Dùng gradient $-y\mathbf{x}$, bỏ mất số hạng $p\mathbf{x}$ (quên rằng $p = 0{,}5$ chứ không phải 0).

▸ Giải thích chi tiết

Thử lại câu này

Câu 20 · T02-C02 · 3 điểm · Trắc nghiệm · Vận dụng · tình huống

Để kiểm code backprop tự viết, bạn so đạo hàm giải tích với sai phân hữu hạn. Thử trên $f(x) = x^3$ tại $x = 1$ với $h = 0{,}1$. Sai phân tiến $\dfrac{f(x+h) - f(x)}{h}$ và sai phân trung tâm $\dfrac{f(x+h) - f(x-h)}{2h}$ lần lượt bằng:

- **A.** $3{,}31$ và $3{,}00$
- **B.** $2{,}71$ và $3{,}01$
- **C.** $3{,}31$ và $3{,}01$
- **D.** $3{,}01$ và $3{,}31$

✗ Chưa đúng: bạn chọn A, đáp án đúng là C.
Ghi câu này vào sổ lỗi, lần sau sẽ nhớ.

Đáp án C. $f(1{,}1) = 1{,}331$, $f(0{,}9) = 0{,}729$. Tiến: $\frac{0{,}331}{0{,}1} = 3{,}31$ (sai số $\approx 3h$, bậc $O(h)$). Trung tâm: $\frac{0{,}602}{0{,}2} = 3{,}01$ (sai số h^2, bậc $O(h^2)$).

- **A:** Tưởng sai phân trung tâm cho kết quả **đúng tuyệt đối**; nó chỉ chính xác cho đa thức bậc ≤ 2, với x^3 còn sai số $h^2 = 0{,}01$.
- **B:** Dùng sai phân **lùi** $\frac{f(x)-f(x-h)}{h} = 2{,}71$ thay cho sai phân tiến.
- **D:** Đảo thứ tự hai công thức; sai phân trung tâm mới là cái gần $f'(1) = 3$ hơn.

▸ Giải thích chi tiết

Thử lại câu này

Câu 21 · T02-C04 · 3,5 điểm · Điền số · Vận dụng · tình huống

Một optimizer bậc hai cần dự đoán loss sau một bước trước khi chấp nhận bước đó. Tại $\mathbf{w}_0$: $L(\mathbf{w}_0) = 5$, $\nabla L(\mathbf{w}_0) = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$, Hessian $H = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}$. Dùng khai triển Taylor bậc hai, ước lượng $L(\mathbf{w}_0 + \boldsymbol{\Delta})$ với $\boldsymbol{\Delta} = \begin{pmatrix} -0{,}5 \\ 0{,}5 \end{pmatrix}$. **Nhập số, làm tròn 2 chữ số thập phân.**

Nhập số

Kiểm tra

Câu 22 · T02-C05 · 3,5 điểm · Điền số · Vận dụng

Tối ưu $L(w) = w^2$ bằng GD có momentum: $v_t = \beta v_{t-1} + L'(w_{t-1})$, $w_t = w_{t-1} - \eta v_t$, với $w_0 = 1$, $v_0 = 0$, $\eta = 0{,}1$, $\beta = 0{,}9$. Tính w_2 (sau 2 bước). **Làm tròn 2 chữ số thập phân.**

Nhập số

Kiểm tra

Câu 23 · T02-C06 · 3 điểm · Trắc nghiệm · Vận dụng · tình huống

Để huấn luyện nhanh hơn, một bạn tăng learning rate. Bài toán thu gọn: $L(w) = 2w^2$, $w_0 = 1$, $\eta = 0{,}6$. Sau 3 bước GD, w_3 bằng bao nhiêu và quá trình diễn ra thế nào?

- **A.** $w_3 = 39{,}304$; w tăng rất nhanh vì đi theo hướng gradient
- **B.** $w_3 = 2{,}744$; w tăng đều về một phía (phân kỳ đơn điệu)
- **C.** $w_3 = -0{,}008$; w đổi dấu nhưng $|w|$ giảm (hội tụ dao động)
- **D.** $w_3 = -2{,}744$; w đổi dấu mỗi bước và $|w|$ tăng dần (phân kỳ dao động)

✗ Chưa đúng: bạn chọn A, đáp án đúng là D.

Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án D. (bản in: A) $L'(w) = 4w$ nên $w_{t+1} = (1 - 4\eta)w_t = -1{,}4\, w_t$; $w_3 = (-1{,}4)^3 = -2{,}744$. Phân kỳ khi $|1 - 4\eta| > 1 \iff \eta > 0{,}5$.

- **A:** Cộng gradient thay vì trừ: $w_{t+1} = (1 + 4\eta)w_t = 3{,}4\, w_t$, tức gradient ascent.
- **B:** Bỏ dấu âm của hệ số $1 - 4\eta = -1{,}4$; hệ số âm làm w **đổi dấu** mỗi bước.
- **C:** Lấy nhầm $L'(w) = 2w$ (quên hệ số 2 của $2w^2$), ra hệ số $1 - 1{,}2 = -0{,}2$ nên tưởng là hội tụ.

▸ Giải thích chi tiết

Thử lại câu này

Câu 24 · T02-C08 · 3 điểm · Trắc nghiệm · Vận dụng

Mạng nhỏ: $h = \mathrm{ReLU}(w_1 x)$, $\hat{y} = w_2 h$, loss $L = \frac{1}{2}(\hat{y} - y)^2$. Với $x = 2$, $y = 1$, $w_1 = 0{,}5$, $w_2 = -1$, cặp gradient $\left(\frac{\partial L}{\partial w_1}, \frac{\partial L}{\partial w_2}\right)$ là:

- A. $(-2;\ 4)$
- B. $(2;\ -2)$
- C. $(-4;\ 2)$
- D. $(4;\ -2)$

✗ Chưa đúng: bạn chọn A, đáp án đúng là D.
Ghi câu này vào sổ lỗi, lần sau sẽ nhớ.

Đáp án D. Xuôi: $w_1 x = 1$, $h = 1$, $\hat{y} = -1$, $\delta = \hat{y} - y = -2$. Ngược: $\frac{\partial L}{\partial w_2} = \delta h = -2$; $\frac{\partial L}{\partial w_1} = \delta \cdot w_2 \cdot \mathrm{ReLU}'(1) \cdot x = (-2)(-1)(1)(2) = 4$.

- **A:** Đúng giá trị nhưng **đảo thứ tự**: gán gradient của w_2 cho w_1 và ngược lại.
- **B:** Quên nhân $x = 2$ ở bước cuối khi tính $\frac{\partial (w_1 x)}{\partial w_1} = x$.
- **C:** Dùng $\delta = y - \hat{y} = 2$ (đạo hàm sai dấu của $\frac{1}{2}(\hat{y} - y)^2$ theo $\hat{y}$), làm cả hai gradient đổi dấu.

▸ Giải thích chi tiết

Thử lại câu này

Câu 25 · T02-C03 · 3 điểm · Trắc nghiệm · Vận dụng · tình huống

Khi huấn luyện, loss gần như đứng yên quanh một điểm có gradient bằng 0. Xấp xỉ cục bộ của loss quanh điểm này là $f(x, y) = x^2 + 4xy + y^2$ tại $(0, 0)$. Kết luận nào đúng?

- A. Cực đại địa phương, vì định thức của Hessian âm
- B. Không kết luận được, vì Hessian không phải ma trận đường chéo
- C. Cực tiểu địa phương, vì các phần tử đường chéo của Hessian đều dương
- D. Điểm yên ngựa, vì Hessian có trị riêng 6 và -2 trái dấu

✗ Chưa đúng: bạn chọn A, đáp án đúng là D.

Không sao, sai ở đây là học được nhiều nhất.

Đáp án D. $H = \begin{pmatrix} 2 & 4 \\ 4 & 2 \end{pmatrix}$, trị riêng 2 ± 4 tức 6 và -2. Trị riêng trái dấu (tương đương $\det H = -12 < 0$) nên $(0, 0)$ là điểm yên ngựa: theo hướng $(1, -1)$ loss **giảm** ($f(t, -t) = -2t^2$).

- **A:** Định thức âm nghĩa là hai trị riêng **trái dấu** (yên ngựa); cực đại cần cả hai trị riêng âm, tức $\det H > 0$ và vết âm.
- **B:** Hessian không cần là ma trận đường chéo; chỉ cần tính trị riêng (hoặc dùng phép thử đạo hàm cấp hai) là kết luận được.
- **C:** Đường chéo dương **chưa đủ** để H xác định dương; phải xét mọi trị riêng (hoặc $\det H > 0$). Ở đây số hạng chéo $4xy$ lấn át.

▸ Giải thích chi tiết

Thử lại câu này

Câu 26 · T02-C01 · 3,5 điểm · Điền số · Vận dụng · tình huống

Một mô hình hồi quy một tham số dùng loss bền vững với ngoại lai $\rho(r) = \ln(1 + r^2)$, trong đó phần dư $r = wx - y$. Với một mẫu $x = 2$, $y = 1$ và tham số hiện tại $w = 1$, tính $\frac{d\rho}{dw}$. **Nhập số, làm tròn 2 chữ số thập phân.**

Nhập số

Kiểm tra

Câu 27 · T02-C07 · 3 điểm · Trắc nghiệm · Vận dụng · tình huống

Một mô hình có hai tham số với gradient ở bước đầu tiên là $g_a = 0{,}001$ và $g_b = 100$. Dùng Adam với $\eta = 0{,}01$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$, $m_0 = v_0 = 0$, **có** hiệu chỉnh bias. Độ lớn bước cập nhật ở bước 1 của hai tham số xấp xỉ là:

- **A.** 10^{-5} và 1
- **B.** $0{,}0316$ cho cả hai
- **C.** $0{,}01$ cho cả hai
- **D.** $0{,}316$ cho cả hai

✗ Chưa đúng: bạn chọn A, đáp án đúng là C.

Gần đúng rồi, xem kỹ bước bị nhầm nhé.

Đáp án C. (bản in: B) $\hat{m}_1 = \frac{0{,}1g}{0{,}1} = g$, $\hat{v}_1 = \frac{0{,}001g^2}{0{,}001} = g^2$; bước $= \eta \frac{\hat{m}_1}{\sqrt{\hat{v}_1}+\epsilon} \approx \eta \cdot \mathrm{sign}(g)$, độ lớn $0{,}01$ bất kể thang đo của gradient.

- **A:** Đây là bước của SGD thuần $\eta|g|$; Adam chia cho $\sqrt{\hat{v}}$ nên độ lớn bước không tỉ lệ với $|g|$.
- **B:** Bỏ hiệu chỉnh bias: $\frac{m_1}{\sqrt{v_1}} = \frac{0{,}1}{\sqrt{0{,}001}} \approx 3{,}16$, nhân η được $0{,}0316$.
- **D:** Chỉ hiệu chỉnh m mà quên hiệu chỉnh v: $\frac{g}{\sqrt{0{,}001}\,|g|} \approx 31{,}6$, nhân η được $0{,}316$.

▸ Giải thích chi tiết

Thử lại câu này

Phần D — Vận dụng cao

Câu 28 · T02-D03 · 6 điểm · Tự luận · Vận dụng cao · tình huống

Trong đồ án môn học, nhóm bạn tự viết một thư viện autograd nhỏ (kiểu micrograd). Để kiểm thử, nhóm dùng biểu thức

$$u = w\,x, \qquad t = 3u, \qquad v = u^2, \qquad L = v + t,$$

với $w = 1$, $x = 2$. Thư viện chạy lượt ngược như sau: đặt `L.grad = 1`, rồi gọi hàm `backward` của từng nút **đúng theo thứ tự** $L \to t \to v \to u$; hàm `backward` của một nút nhân gradient của chính nó với đạo hàm cục bộ rồi ghi vào `.grad` của các nút đầu vào. Một bạn cài phép ghi này bằng cách **gán đè** `a.grad = ...` thay vì **cộng dồn** `a.grad += ...`.

(a) Vẽ (hoặc mô tả) đồ thị tính toán, tính giá trị các nút và chỉ ra nút nào có nhiều hơn một nhánh đi ra.

(b) Dùng quy tắc chuỗi nhiều biến để tính đúng $\frac{\partial L}{\partial u}$ và $\frac{\partial L}{\partial w}$. Kiểm lại bằng cách viết L trực tiếp theo w rồi đạo hàm.

(c) Với cách cài **gán đè** và thứ tự $L \to t \to v \to u$ ở trên, lần lượt ghi giá trị `u.grad` sau mỗi lệnh ghi, rồi cho biết thư viện trả ra `w.grad` bằng bao nhiêu. Giải thích vì sao sai và đề xuất một test tự động bắt được lỗi này.

(d) Liên hệ: trong khối residual $\mathbf{y} = \mathbf{x} + F(\mathbf{x})$ của ResNet, cũng có một nút "rẽ nhánh". Dùng đúng nguyên tắc ở câu (b), giải thích vì sao khối này giúp gradient đi qua mạng sâu dễ hơn.

Viết câu trả lời…

Xem bài mẫu & rubric Viết thử trước rồi hãy mở.

Câu 29 · T02-D02 · 6 điểm · Tự luận · Vận dụng cao · tình huống

Nhóm bạn xây mạng nhỏ dự đoán khách hàng có gia hạn gói dịch vụ hay không ($y = 1$: gia hạn). Một khách hàng có đặc trưng $\mathbf{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ và nhãn $y = 1$. Mạng:

$$\mathbf{a} = W^{(1)}\mathbf{x} + \mathbf{b}^{(1)}, \quad \mathbf{h} = \mathrm{ReLU}(\mathbf{a}), \quad z = \mathbf{w}^{(2)\top}\mathbf{h} + b^{(2)}, \quad p = \sigma(z), \quad L = -\big[y \ln p + (1 -$$

với $W^{(1)} = \begin{pmatrix} 1 & -1 \\ 0{,}5 & 0{,}5 \end{pmatrix}$, $\mathbf{b}^{(1)} = \mathbf{0}$, $\mathbf{w}^{(2)} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$, $b^{(2)} = -1{,}5$.

(a) Tính lượt xuôi: $\mathbf{a}$, $\mathbf{h}$, z, p và L.

(b) Lan truyền ngược: tính $\frac{\partial L}{\partial z}$, $\frac{\partial L}{\partial \mathbf{w}^{(2)}}$, $\frac{\partial L}{\partial b^{(2)}}$, $\frac{\partial L}{\partial \mathbf{h}}$, $\frac{\partial L}{\partial \mathbf{a}}$, $\frac{\partial L}{\partial W^{(1)}}$, $\frac{\partial L}{\partial \mathbf{b}^{(1)}}$. Giải thích vì sao một hàng của $\frac{\partial L}{\partial W^{(1)}}$ bằng 0.

(c) Cập nhật mọi tham số bằng **một bước** GD với $\eta = 0{,}5$, rồi chạy lại lượt xuôi để chứng tỏ loss đã giảm (cho biết $\sigma(2{,}875) \approx 0{,}947$).

(d) Nêu cách kiểm một phần tử gradient bằng sai phân hữu hạn và một rủi ro khi kiểm gradient qua ReLU.

Viết câu trả lời…

Xem bài mẫu & rubric Viết thử trước rồi hãy mở.

Câu 30 · T02-D01 · 3,5 điểm · Điền số · Vận dụng cao

Cho loss bậc hai $L(w_1, w_2) = w_1^2 + w_1 w_2 + w_2^2 - 3w_1$. Xuất phát từ $\mathbf{w}_0 = (0, 0)$, so sánh hai cách đi một bước: (i) **Newton**: $\mathbf{w}_N = \mathbf{w}_0 - H^{-1}\nabla L(\mathbf{w}_0)$, với H là Hessian; (ii) **GD**:

$\mathbf{w}_G = \mathbf{w}_0 - \eta \nabla L(\mathbf{w}_0)$ với $\eta = 0{,}5$. Tính $L(\mathbf{w}_G) - L(\mathbf{w}_N)$. **Nhập dạng thập phân, làm tròn 2 chữ số.**

Nhập số

Kiểm tra